

Notas Metodológicas — Dimensão 3: Perfil Sociodemográfico Municipal

Projeto DSIP-MT | D3_PSDM

Script gerador: 02_Analise/Scripts/D3_PSDM.R **Cobertura geográfica:** 141 municípios de Mato Grosso (13 Pantanal Norte = sujeito; 2 polo metropolitano = Cuiabá + Várzea Grande; 126 resto MT — comparadores) **Chave:** id_municipio (IBGE 7 dígitos) × ano **Recorte Pantanal Norte (PN-13):** definição institucional do convênio SUDECO/UNEMAT (não derivada de critério estatístico — decisão do coordenador com a SUDECO, registrada no TdR assinado em 04/11/2025) **Documento vivo** — atualizado à medida que novos outputs são gerados. Criado em 14/06/2026.

CORREÇÕES DA AUDITORIA FORENSE (11/06-14/06/2026) que afetam o D3:

- **D-3 (assistência social):** as bases C14 Bolsa Família e C14 BPC são **mensais** (1 linha = 1 favorecido × competência). O `n()` anterior somava as ~12 competências do ano (família-mês), inflando `n_beneficiarios_bf` em ~12× (`perc_pop_bf` chegava a 247%). Substituído por **média mensal de identificadores distintos** (NIS para BF; `numero_beneficio` para BPC). Detalhe na seção do arquivo 2.
- **D-4 (mortalidade infantil):** `tmi` passou a ser **suprimida (NA) quando nascidos-vivos < 30** (taxas instáveis em municípios pequenos — ex.: Rondolândia com TMI 1000‰ a partir de 1 nascimento). `tmi_suavizado` foi redefinida como **taxa agregada da janela móvel de 3 anos** (Σ óbitos infantis / Σ NV), não média de taxas anuais. Detalhe na seção do arquivo 6.
- **M-2 (ANS):** `perc_cobertura_ans` passou a ter **teto de 100%** (`pmin(100, ...)`) — beneficiários vinculados a polos regionais podem exceder a população residente estimada (máx. observado: 166,9%). Para magnitude real em polos, usar `beneficiarios_ans` absoluto.
- **Docentes com superior (14/06/2026):** a codificação de escolaridade do C18 muda em 2015; o limiar fixo `>= 6` zerava 2015–2020. Fix condicional ao ano. Detalhe na seção do arquivo 5.
- **Helper `ler_csv()` / `resolver_arquivo()`:** prefere automaticamente arquivos `*_corrigido.csv` quando existem (gerados por 00_FIX_AUDITORIA.R). Garante uso das versões saneadas de C15, C17, C21, C22, C23, C24, C34.
- **Travas de unidade:** `stopifnot` impede gravar `d3_idhm.csv` e `d3_painel_psdm.csv` com a chave (id_municipio, ano) duplicada (após os dedups defensivos de C15 e C34).

Outputs desta dimensão

Arquivo	Lin × Col	Cobertura temporal	Notas
d3_demografico.csv	3.645 × 19	2000–2025 (série anual) + Censo 2022 (raça/urbanização)	âncora da dimensão
d3_assistencia_social.csv	1.692 × 16	2013–2024 (útil)	BF + BPC, R\$ de 2024 (INPC)

Arquivo	Lin × Col	Cobertura temporal	Notas
d3_idhm.csv	512 × 12	1970, 1980, 1991, 2000, 2010 (censitários)	IDHM + Gini + pobreza
d3_educacao_qualidade.csv	1.410 × 38	bienal 2005–2023 (10 ondas, incl. 2015; sem 2025)	IDEB + SAEB (bloco SAEB/C20 preenchido 2011–2021)
d3_educacao_infraestrutura.csv	2.538 × 25	2007–2024 (escolas/fluxo); docentes 2009–2020	Censo Escolar + INEP
d3_saude_mortalidade.csv	3.218 × 17	2000–2022	SIM + SINASC
d3_saude_infraestrutura.csv	564 × 15	2010, 2015, 2020, 2023 (snapshots)	CNES + ANS
d3_painel_psd.csv	3.645 × 43	2000–2025 (join dos 7 CSVs)	painel consolidado

Nota sobre o d3_idhm.csv: nesta execução o pivot do C15 produziu apenas a coluna idhm (índice sintético). Os subíndices idhm_e/idhm_l/idhm_r são incorporados via any_of() — só entram no CSV quando presentes na fonte sob esses nomes; na versão corrente do C15 corrigido eles não aparecem como linhas indicador mapeadas, de modo que a **versão congelada entregue na Fase I traz 12 colunas (sem os três subíndices)**. O script está preparado para incluí-los assim que estiverem disponíveis, sem alteração de código.

Fontes Primárias

Sigla	Arquivo	Tema	Fonte	Período
C12	C12_populacao_ibge.csv	População residente	IBGE (estimativas anuais + censos)	2000–2025
C13	C13_censo_2022.csv	Composição por cor/raça (formato bruto SIDRA)	IBGE/Censo 2022	2022

Sigla	Arquivo	Tema	Fonte	Período
C13b	C13b_urbanizacao_censo2022.csv	População por situação do domicílio (urbano/rural)	IBGE/Censo 2022 (SIDRA T9923)	2022
C14	C14_bolsa_familia.csv	Pagamentos Bolsa Família / Auxílio Brasil (mensal)	CGU/Portal da Transparência via BD	2012-2025
C14	C14_bpc.csv	Pagamentos BPC (mensal)	CGU/Portal da Transparência via BD	2019-2025
C15	C15_idhm_corrigido.csv	IDHM e subíndices (formato longo)	PNUD/IPEA/FJP — Atlas do Desenvolvimento Humano	1970-2010 (censitários)
C17	C17_ideb_corrigido.csv	IDEB, aprovação e notas SAEB padronizadas	INEP/IDEB via BD (+ recoleta 2015)	2005-2023 (bienal)
C18	C18_censo_escolar_escolas.csv	Infraestrutura escolar (455 col.)	INEP/Censo Escolar via BD	2007-2024
C18	C18_censo_escolar_docentes.csv	Escolaridade e especialização docente (126 col.)	INEP/Censo Escolar via BD	2009-2020
C19	C19_indicadores_educacionais.csv	TDI, aprovação, reprovação, abandono (215 col., pré-agregado)	INEP via BD	2006-2024
C20	C20_saeb_avaliacao.csv	Proficiência SAEB por nível	INEP/SAEB via BD	2011-2023 (bienal)
C21	C21_sim_mortalidade_corrigido.csv	Óbitos — microdado (92 col.)	MS/SVS — SIM via BD	2000-2022

Sigla	Arquivo	Tema	Fonte	Período
C22	C22_sinasc_nascimentos_corrigido.csv	Nascidos vivos — microdado (66 col.)	MS/SVS — SINASC via BD	2000-2023
C23	C23_ans_saude_suplementar_corrigido.csv	Beneficiários de planos de saúde (36 col., nomenclatura ANS)	ANS — dados abertos	mensal (competência), 2010-2023
C24	C24_cnes_estabelecimentos_corrigido.csv	Estabelecimentos, leitos e tipo de unidade (217 col.)	MS/CNES via BD	2010-2023
C34	C34_ipeadata_indicadores_sociais_corrigido.csv	Gini, pobreza, extrema pobreza, pop. censitária	IPEADATA (censos demográficos)	1991, 2000, 2010
C35	C35_deflator_pib.csv	INPC base 2010 = 100 (e deflator SCN — não usado no D3)	IBGE/INPC via IPEADATA	2000-2024

Referência geográfica: Dados/painel_mestre/municipios_ref.csv fornece id_municipio, municipio, pantanal_norte (flag). Define IDS_MT (141), IDS_PN (13) e o mapa cod6 → id_municipio (6→7 dígitos) usado para casar a ANS, que opera com código sem dígito verificador.

Deflator

INPC (base 2010 = 100) — único deflator do D3, aplicado exclusivamente às **variáveis monetárias de assistência social** (Bolsa Família e BPC). As demais variáveis do D3 são **contagens** (óbitos, nascimentos, escolas, leitos, beneficiários) e **taxas/índices** (IDEB, IDHM, Gini, TMI, percentuais) — não deflacionadas.

- **Fonte:** IBGE/INPC — série via IPEADATA; coluna deflator_inpc_2010 em C35_deflator_pib.csv.
- **Cobertura conceitual:** famílias com renda de 1 a 5 salários mínimos — perfil compatível com o público de transferências de renda, mais adequado que o IPCA.

- **Rebase para R\$ de 2024:** $\text{fator_rebase} = \text{inpc_2024} / \text{deflator_inpc_2010}$, onde inpc_2024 é o valor da série em 2024. Cada valor nominal é multiplicado por esse fator → R\$ de 2024.
- **Aplicação:** $\text{valor_medio_bf_real}$, $\text{valor_total_bf_real}$, $\text{valor_total_bpc_real}$ e transf_pc_real (esta última deflaciona a soma nominal BF+BPC antes do per capita).

O nome $\text{deflator_inpc_2010}$ refere-se à **série-fonte** (base 2010 = 100), não à base dos outputs. Após o rebase, os valores $_real$ estão em **R\$ de 2024**, coerentes com o D1.

Construção por base

Para cada arquivo: seção do D3_PSDM.R, fonte(s) primária(s), cobertura, tabela de variáveis-chave com construção/fórmula e notas de cuidado. Todas as bases incluem o cabeçalho comum de identificação: id_municipio , municipio , grupo (pantanal_norte / $\text{polo_metropolitano}$ / resto_mt), subgrupo (Pantanal-13 / $\text{Polo Metropolitano}$ / Demais MT), pantanal_norte (flag lógica), ano .

Arquivo 1 — d3_demografico.csv

Seção do script: D3_PSDM.R — Seção [1/8] **Fontes primárias:** C12 (população anual), C13 (composição racial Censo 2022), C13b (urbanização Censo 2022) **Cobertura:** 141 municípios × 2000–2025 (série anual) | indicadores 2022 replicados na série | 3.645 linhas × 19 colunas — municípios instalados após 2000 entram na série apenas a partir de 2001 (13 casos) ou 2004 (Ipiranga do Norte e Itanhangá), por isso a grade tem 3.645 e não $141 \times 26 = 3.666$ linhas

Grupo 1 — População e dinâmica demográfica (C12)

Variável	Construção / Fórmula
populacao	População residente IBGE (C12), série anual 2000–2025 — âncora do D3
$\text{cagr_pop_2000_2025}$	$\text{cagr_pct}(\text{pop_2000}, \text{pop_2025}, 25)$ — CAGR composto entre anos-pivot
$\text{cagr_pop_2010_2025}$	$\text{cagr_pct}(\text{pop_2010}, \text{pop_2025}, 15)$
$\text{cagr_pop_2010_2022}$	$\text{cagr_pct}(\text{pop_2010}, \text{pop_2022}, 12)$

Helper $\text{cagr_pct}(\text{ini}, \text{fim}, \text{n})$ = $((\text{fim}/\text{ini})^{(1/\text{n})} - 1) \times 100$, arredondado a 2 casas; retorna NA se algum valor for ausente ou ≤ 0 . Os três CAGR são **constantes por município** (mesmo valor em todos os anos da série).

Distinguir CAGR agregado de média simples: o CAGR de um grupo (ex.: PN-13) calculado sobre a **população total do grupo** difere fortemente da

média simples dos CAGR municipais quando há um município dominante. No PN-13, Rondonópolis concentra ~53% da população: o CAGR agregado 2010-2025 é +1,04%, mas a média simples dos 13 municípios é +0,04% (revela estagnação mascarada). Reportar ambos.

Grupo 2 — Composição racial (C13 — Censo 2022 apenas)

Variável	Construção / Fórmula
pop_total_censo	Σ das categorias raciais (branca+preta+parda+amarela+indígena), Censo 2022
sh_pop_branca	$\text{pop_branca} / \text{pop_total_censo} \times 100$
sh_pop_preta	$\text{pop_preta} / \text{pop_total_censo} \times 100$
sh_pop_parda	$\text{pop_parda} / \text{pop_total_censo} \times 100$
sh_pop_amarela	$\text{pop_amarela} / \text{pop_total_censo} \times 100$
sh_pop_indigena	$\text{pop_indigena} / \text{pop_total_censo} \times 100$

O C13 vem no **formato bruto da API SIDRA** (1 linha = município × categoria racial). O script faz `pivot_wider` por Cor ou raça (somando com `values_fn = sum`), `clean_names()` e renomeia as categorias para `pop_*`. Todos os shares são **valores únicos de 2022 replicados em toda a série anual** (NÃO interpolados) — interpretar como retrato de 2022. Arredondamento a 1 casa decimal.

Grupo 3 — Urbanização (C13b — Censo 2022 apenas, NOVO 14/06/2026)

Variável	Construção / Fórmula
pop_urbana	População em domicílio urbano (Censo 2022, SIDRA T9923)
pop_rural	População em domicílio rural (Censo 2022)
taxa_urbanizacao	$\text{pop_urbana} / (\text{pop_urbana} + \text{pop_rural}) \times 100$ (calculado na coleta C13b)

Lacuna preenchida em 14/06/2026 (script de coleta `C13b_urbanizacao_censo2022.R`). 141 municípios, 0% NA. Como a composição racial, é **valor único de 2022 replicado na série**. PN-13: 67,3% (média simples) / 86,3% (ponderada pela população).

Consolidação: `d3_demografico` parte da série `pop_anual` (C12) e faz `left_join` dos três blocos por `id_municipio` (CAGR e indicadores 2022) e `municipios_ref` (nome, flag PN). grupo/subgrupo atribuídos pelos helpers `classifica_grupo()/classifica_subgrupo()`.

Arquivo 2 — d3_assistencia_social.csv

Seção do script: D3_PSDM.R — Seção [2/8] **Fontes primárias:** C14 Bolsa Família (2,7 GB) + C14 BPC (682 MB) — leitura com `vroom` e `col_select` **Deflator:** INPC (base 2010 = 100) → R\$ de 2024 **Cobertura:** 141 municípios × 2013-2024 (janela útil) | 16 colunas

FIX D-3 (11/06/2026) — estrutura mensal das fontes: C14 BF e C14 BPC são bases **mensais** (1 linha = 1 favorecido/benefício × competência). O agregador correto toma a **média mensal de identificadores distintos no ano**: NIS (`nis_favorecido`) para BF; `numero_beneficio` para BPC (o NIS do BPC traz códigos inválidos como “-3”). Os programas BF → Auxílio Brasil → BF reformulado são somados dentro do mês.

Grupo 1 — Bolsa Família

Variável	Construção / Fórmula
<code>n_beneficiarios_bf</code>	<code>round(mean(n_familias_mes))</code> — média mensal de NIS distintos no ano
<code>valor_total_bf_real</code>	$\Sigma \text{valor anual pago} \times \text{fator_rebase} / 1e6 \rightarrow \text{R\$ milhões de 2024}$
<code>valor_medio_bf_real</code>	$(\Sigma \text{valor anual} / \Sigma \text{famílias-mês}) \times \text{fator_rebase} \rightarrow \text{benefício médio por família-mês, R\$ de 2024}$
<code>perc_pop_bf</code>	<code>n_beneficiarios_bf / populacao × 100</code>

`perc_pop_bf` = FAMÍLIAS por 100 habitantes, NÃO % de pessoas. Valores > 100% seriam legítimos (proxy de cobertura/intensidade, não de proporção de indivíduos). Rotular sempre “famílias por 100 hab”.

Grupo 2 — BPC (Benefício de Prestação Continuada)

Variável	Construção / Fórmula
<code>n_beneficiarios_bpc</code>	<code>round(mean(n_benef_mes))</code> — média mensal de <code>numero_beneficio</code> distintos no ano
<code>valor_total_bpc_real</code>	$\Sigma \text{valor anual} \times \text{fator_rebase} / 1e6 \rightarrow \text{R\$ milhões de 2024}$
<code>perc_pop_bpc</code>	<code>n_beneficiarios_bpc / populacao × 100</code> — benefícios ativos por 100 hab

Embora a fonte do BPC comece em 2019, a janela é alinhada com o BF (2013-2024) para que `total_beneficiarios` some grandezas coerentes; nos anos 2013-2018 o BPC entra como ausente (NA) via `full_join`.

Grupo 3 — Consolidados de assistência

Variável	Construção / Fórmula
total_beneficiarios	coalesce(n_bf,0) + coalesce(n_bpc,0)
perc_pop_total_assist	total_beneficiarios / populacao × 100
transf_pc_real	(valor_total_bf_brl + valor_total_bpc_brl) × fator_rebase / populacao → R\$ de 2024/hab

transf_pc_real deflaciona a **soma nominal** BF+BPC antes de dividir pela população — coerente com a deflação dos demais _real. fator_rebase = inpc_2024 / deflator_inpc_2010.

Janela 2013-2024. 2012 truncado na fonte (só parcelas retroativas jundez pagas em 2013); 2025 parcial. **Não usar as pontas.** As competências estão em ano/mes (mês de referência da folha); ano_referencia/mes_referencia identificam a folha de pagamento.

Arquivo 3 — d3_idhm.csv

Seção do script: D3_PSDM.R — Seção [3/8] **Fontes primárias:** C15 IDHM (Atlas/PNUD, formato longo) + C34 IPEADATA (Gini/pobreza) **Cobertura:** 141 municípios × anos censitários (1970, 1980, 1991, 2000, 2010) | 512 linhas × 12 colunas — nem todos os municípios existiam nos censos mais antigos (34 em 1970; 55 em 1980; 141 de 1991 em diante)

Grupo 1 — IDHM e classificação (C15)

Variável	Construção / Fórmula
idhm	Índice sintético (pivot do formato longo indicador × valor → wide; clean_names())
classifica_idhm	Faixas PNUD: ≥0,800 Muito Alto; ≥0,700 Alto; ≥0,600 Médio; ≥0,500 Baixo; senão Muito Baixo
var_idhm_2000_2010	idhm[ano==2010] - idhm[ano==2000], arredondado a 3 casas (constante por município)

O C15 é **longo** (1 linha = município × ano × indicador). O script aplica distinct(id_municipio, ano, indicador) **antes** do pivot (dedup defensivo — duplicatas gerariam list-columns silenciosas) e pivot_wider por indicador. Os subíndices idhm_e (educação), idhm_l (longevidade), idhm_r (renda) entram via any_of() **se** presentes na fonte sob esses nomes — nesta execução não aparecem mapeados, e o CSV final fica sem eles (ver nota em “Outputs desta dimensão”).

Grupo 2 — Desigualdade e pobreza (C34/IPEADATA)

Variável	Construção / Fórmula
gini	Índice de Gini da renda domiciliar per capita (anos censitários)
taxa_pobreza_pct	Proporção de pobres (%)
taxa_ext_pobreza_pct	Proporção de extremamente pobres (%)

O C34 traz Gini/pobreza para **1991, 2000 e 2010**. `distinct(id_municipio, ano)` é aplicado antes do `left_join` (dedup defensivo pós-patch M1b — versões anteriores do C34 corrigido tinham linhas repetidas idênticas que o `join` propagava). Verificado em 14/06/2026: 141 municípios com Gini em 2010 (range 0,38–0,69).

Trava de unicidade: `stopifnot` aborta a gravação se a chave (`id_municipio, ano`) ficar duplicada.

Anos exclusivamente censitários — último = 2010 (defasagem de 15 anos relativa a 2025). **Rotular sempre “Censo 2010”**; usar como cortes, não como série anual nem situação atual.

Arquivo 4 — d3_educacao_qualidade.csv

Seção do script: D3_PSDM.R — Seção [4/8] **Fontes primárias:** C17 IDEB + C20 SAEB **Cobertura:** 141 municípios × série bienal 2005–2023 (10 ondas, incl. 2015) | 1.410 linhas × 38 colunas

Grupo 1 — IDEB (C17) — filtro rede == "publica"

Variável	Construção / Fórmula
ideb_iniciais / ideb_finais	IDEB da rede pública por etapa (anos iniciais / finais do EF)
taxa_aprovacao_iniciais / _finais	Taxa de aprovação por etapa
nota_saeb_matematica_* / nota_saeb_lingua_portuguesa_*	Proficiência SAEB que compõe o IDEB, por etapa

A etapa é derivada por **regex** sobre `anos_escolares`: “iniciais” → `iniciais`; “finais” → `finais`; “médio” → `medio`; demais combinações geram um sufixo sanitizado (daí surgir, p.ex., `ideb_todos_1_4_` quando a fonte traz rótulos agregados). `pivot_wider` espalha `ideb`, `taxa_aprovacao` e as duas notas SAEB por etapa.

Colunas residuais de pivot (*_todos_1_4_): as quatro colunas `ideb_todos_1_4_`, `taxa_aprovacao_todos_1_4_`, `nota_saeb_matematica_todos_1_4_` e `nota_saeb_lingua_portuguesa_todos_1_4_` vêm do rótulo agregado

“todos (1ª a 4ª série)” presente na fonte apenas a partir de 2017 (preenchidas em 2017-2023; 61-73% NA no total). São **residuais do pivot — ignorar nas análises**; usar sempre as colunas por etapa _iniciais/_ finais.

Grupo 2 — SAEB (C20) — sistema total, localização total

Variável	Construção / Fórmula
media_{lp,mt}_{5,9,12,4,14}ano	Proficiência média por disciplina (LP/MT) × série
perc_nivel_adequado_{lp,mt}_{...}ano	Σ dos % nos níveis ≥ 6 da escala SAEB (nivel_6+...+nivel_10)

O SAEB não tem rede == "total"; o filtro usa str_starts(rede, "total - federal, estadual, municipal") e localizacao == "total". A chave de coluna combina as 2 primeiras letras da disciplina + a série (paste0(str_sub(disciplina,1,2), "_", série, "ano")), pivotada com values_fn = mean. perc_nivel_adequado = % de alunos em nível básico ou acima.

Códigos de etapa (coluna serie da fonte BD): 5 e 9 = 5º e 9º anos do EF — séries principais, preenchidas em 2011-2021 na versão congelada; **12** = etapa do ensino médio (preenchida em 2011, 2017, 2019 e 2021); **4 e 14** = códigos raros de etapa do EM na fonte — **residuais de pivot**: _4ano só em 2017/2019 (≤ 30 municípios; proficiência média ~287, nível de EM) e _14ano só em 2021 e apenas nos perc_nivel_adequado_* (25 municípios; as colunas media_lp_14ano/media_mt_14ano estão **inteiramente vazias**). Nas análises, usar _5ano/_9ano (EF) e _12ano (EM); ignorar _4ano/_14ano.

Série bienal 2005-2023 (2005, 07, 09, 11, 13, 15, 17, 19, 21, 23 — 10 ondas). Na versão congelada da Fase I, **2015 está presente** tanto no IDEB (recoleta complementar do C17) quanto no SAEB (C20); **2025 não publicado**. O bloco SAEB (C20) cobre **2011-2021**: em 2023 as colunas media_*/perc_nivel_adequado_* ficam vazias porque o rótulo de rede da fonte muda para “total - federal, estadual e municipal” e não casa com o filtro str_starts(rede, "total - federal, estadual, municipal"). Aprovação 2023 $\approx$ patamar de MT (sem gargalo); o gargalo está nas notas IDEB iniciais/finais, abaixo de MT e do patamar de 2017.

Arquivo 5 — d3_educacao_infraestrutura.csv

Seção do script: D3_PSDM.R — Seção [5/8] **Fontes primárias:** C18 Escolas (455 col.) + C18 Docentes (852 MB) + C19 Indicadores (215 col., pré-agregado) **Cobertura:** 141 municípios × 2007-2024 (escolas/fluxo); docentes 2009-2020 | 25 colunas

Grupo 1 — Infraestrutura escolar (C18 Escolas)

Variável	Construção / Fórmula
n_escolas_total	n() — escolas por município/ano
n_escolas_publicas	sum(rede %in% c("1","2","3")) — Federal/Estadual/Municipal (exclui "4" Privada)
perc_agua_pub	mean(agua_rede_publica == 1) × 100
perc_energia_pub	mean(energia_rede_publica == 1) × 100
perc_esgoto_pub	mean(esgoto_rede_publica == 1) × 100
perc_internet	mean(internet == 1) × 100
perc_biblioteca	mean(biblioteca_sala_leitura == 1) × 100
perc_lab_info	mean(laboratorio_informatica == 1) × 100

Os percentuais de infraestrutura são calculados sobre **todas** as escolas do município (públicas e privadas), não apenas as públicas. rede é código numérico em string ("1"-"4"). Leitura com vroom selecionando ~10 das 455 colunas.

Grupo 2 — Corpo docente (C18 Docentes)

Variável	Construção / Fórmula
n_docentes	n() após distinct(ano, id_municipio, id_docente) — dedup do docente que aparece em várias turmas/escolas
perc_docentes_superior	mean(docente_superior) × 100, com docente_superior = (escolaridade == 6) se ano ≤ 2014, (escolaridade == 4) se ano ≥ 2015
perc_docentes_especial	mean(especializacao == 1) × 100

FIX perc_docentes_superior (14/06/2026): bug de processamento. A codificação de escolaridade do C18 **muda em 2015**: escala 1-6 com superior = 6 (2009-2014); escala 1-4 com superior = 4 (2015-2020). O limiar fixo >= 6 zerava o indicador em 2015-2020. Fix condicional ao ano. Série agora plausível: 69% (2009) → 85% (2020). **Limitação remanescente:** o C18 docentes coletado cobre só **2009-2020** → indicador é **NA em 2021-2024** (ausência da fonte, não bug).

Pendência menor: perc_docentes_especial usa especializacao == 1, coluna com NA em 2011-2014 — pode instabilizar esses 4 anos; revisar à parte.

Grupo 3 — Fluxo escolar (C19 — pré-agregado INEP, filtro localizacao == "total" e rede == "total")

Variável	Descrição
tdi_ef_anos_iniciais / _ finais / tdi_em	Taxa de distorção idade-série (EF iniciais/finais, EM)
taxa_aprovacao_ef_anos_iniciais / _ finais	Aprovação no EF (fluxo INEP)
taxa_abandono_ef_anos_iniciais / _ finais / taxa_abandono_em	Abandono no EF iniciais/finais e no EM

O C19 é **pré-agregado** pelo INEP (não é microdado); o script apenas seleciona ~14 das 215 colunas e filtra o recorte total/total. TDI, aprovação e abandono já vêm prontos por etapa. As taxas de reprovação são lidas mas não entram no output final.

Consolidação: `escolas_agg ← left_join docentes_agg ← left_join ind_ed, por (id_municipio, ano)`. Como docentes vai só até 2020 e o C19 até 2024, há NAs esperados nas colunas docentes para 2021-2024.

Arquivo 6 — d3_saude_mortalidade.csv

Seção do script: D3_PSDM.R — Seção [6/8] **Fontes primárias:** C21 SIM (127 MB) + C22 SINASC (288 MB) **Cobertura:** 141 municípios × 2000-2022 | 17 colunas **Chave geográfica:** `id_municipio_residencia` (município de residência do falecido/da mãe), **não** ocorrência

Grupo 1 — Óbitos (C21 SIM)

Variável	Construção / Fórmula
n_obitos	<code>n()</code> — óbitos por município de residência/ano
obitos_infantis	Óbitos com idade < 1 ano (inclui neonatos com idade em fração, ex.: 0,07 ≈ 26 dias)
obitos_causas_ext	Óbitos com <code>causa_basica</code> em CID-10 V00-Y89 — regex <code>^[VWX] ^Y[0-8]</code>

idade convertida a numérico (anos). Óbitos com `id_municipio_residencia` = "5100000" (código UF genérico) são descartados pelo filtro `%in% IDS_MT`.

Grupo 2 — Nascimentos (C22 SINASC)

Variável	Construção / Fórmula
n_nascidos_vivos	<code>n()</code> — nascidos vivos por município de residência da mãe/ano
perc_baixo_peso	<code>mean(peso < 2500) × 100</code> (gramas)
perc_cesareas	<code>mean(tipo_parto == 2) × 100</code> (1=normal, 2=cesáreo)

Variável	Construção / Fórmula
perc_prenatal_adequado	$\text{mean}(\text{pre_natal_agr} == 4) \times 100 - 7 + \text{consultas (critério MS estrito)}$
perc_apgar5_baixo	$\text{mean}(\text{apgar5} < 7) \times 100$

pre_natal_agr: 1=nenhuma, 2=1-3, 3=4-6, 4=7+ consultas. O indicador usa **só a categoria 4** (≥ 7), critério MS estrito — por isso o “déficit” do pré-natal adequado tende a parecer maior que em definições mais frouxas.

Grupo 3 — Taxas derivadas

Variável	Construção / Fórmula
tmi	$\text{obitos_infantis} / \text{n_nascidos_vivos} \times 1000$, NA se n_nascidos_vivos < 30
tmi_suavizado	$\Sigma \text{óbitos_inf}(3a) / \Sigma \text{NV}(3a) \times 1000$ (janela móvel 3 anos, alinhamento à direita), NA se $\Sigma \text{NV}(3a) < 30$
taxa_mort_ext_100k	$\text{obitos_causas_ext} / \text{populacao} \times 100.000$

FIX D-4 (11/06/2026): a tmi bruta era instável em municípios pequenos (ex.: Rondolândia, TMI 1000‰ a partir de 1 nascimento). Duas correções: (1) **supressão estatística** — tmi só é reportada com $\text{n_nascidos_vivos} \geq 30$; (2) tmi_suavizado passou a ser a **taxa agregada da janela de 3 anos** (soma de óbitos / soma de NV), não a média de taxas anuais ruidosas. Os helpers `rollsum3()` somam a janela (alinhamento à direita). **Preferir tmi_suavizado para tendência.**

Consolidação: `obitos_total` $\leftarrow$ joins de `obitos_infantis`, `obitos_ext`, `nascimentos_agg` e `pop_anual` por (`id_municipio`, `ano`); `obitos_infantis/obitos_causas_ext` recebem `coalesce(..., 0)` antes das taxas. SIM cobre 2000-2022; SINASC vai até 2023, mas o output é limitado pela interseção com mortalidade.

Arquivo 7 — d3_saude_infraestrutura.csv

Seção do script: D3_PSDM.R — Seção [7/8] **Fontes primárias:** C24 CNES (217 col.) + C23 ANS (2,1 GB, nomenclatura ANS) **Cobertura:** 141 municípios $\times$ 2010, 2015, 2020, 2023 (snapshots) | 15 colunas

Grupo 1 — Estabelecimentos e leitos (C24 CNES)

Variável	Construção / Fórmula
n_estabelecimentos	<code>n()</code> — estabelecimentos por município/ano

Variável	Construção / Fórmula
n_hospitais	sum(e_hospital), e_hospital = str_detect(tp_unid, "hospital pronto socorro pronto atend") (ignore_case)
n_ubs	sum(e_ubs), e_ubs = str_detect(tp_unid, "unidade b.sica posto de sa centro de sa.de unidade mista")
leitos_totais	sum(leithosp) — leitos hospitalares totais
leitos_sus_total	sum(qtleitp1 + qtleitp2 + qtleitp3) — SUS ordinário + complementar + UCI SUS
leitos_sus_per_1000	leitos_sus_total / populacao × 1000
estab_per_10k	n_estabelecimentos / populacao × 10.000

A regex usa “.” como coringa para vogais acentuadas (b.sica, sa.de). As colunas serap* (serviços/profissionais) são Sim/Não na base BD — sem contagem numérica de profissionais, por isso não há indicador de pessoal de saúde neste arquivo.

Grupo 2 — Saúde suplementar (C23 ANS)

Variável	Construção / Fórmula
beneficiarios_ans	Σ QT_BENEFICIARIO_ATIVO por município/ano (granularidade mensal × faixa × sexo agregada)
perc_cobertura_ans	$\text{pmin}(100, \text{beneficiarios_ans} / \text{populacao} \times 100)$ — teto de 100%

Casamento geográfico: a ANS usa CD_MUNICIPIO de **6 dígitos** (sem dígito verificador); o script faz str_pad a 6 e left_join pelo mapa cod6 → id_municipio (7 dígitos). ano é extraído de ID_CMPT_MOVEL (YYYYMM).

FIX 15/05/2026 (filtro de segmentação): o filtro antigo buscava “MEDICO” em DE_SEGMENTACAO_PLAN0, mas o vocabulário real do campo é assistencial (“Ambulatorial”, “Hospitalar com obstetrícia”, “Odontológico”, “Referência”, “Não Identificado”). Substituído por **exclusão estrita de planos exclusivamente odontológicos** (!str_detect(toupper(segmentacao), “^ODONTO”)) — mantém planos mistos como saúde suplementar com componente médico.

FIX M-2 (11/06/2026): perc_cobertura_ans ganhou **teto de 100%** — beneficiários vinculados a polos regionais excediam a população residente (máx. 166,9%). **Para magnitude real em polos, usar beneficiarios_ans absoluto.**

Snapshots — só 2010, 2015, 2020, 2023. O CNES foi coletado nesses 4 anos; a ANS é casada nos mesmos cortes. Não há série anual contínua de infraestrutura de saúde.

Arquivo 8 — d3_painel_psdm.csv

Seção do script: D3_PSDM.R — Seção [8/8] **Construção:** join consolidado dos 7 CSVs sobre a âncora pop_anual (141 mun. × 2000–2025) **Cobertura:** 3.645 linhas × 43 colunas (mesma grade da âncora demográfica — ver Arquivo 1)

O painel parte da grade completa município × ano (série de população) e faz left_join de subconjuntos de variáveis de cada bloco, preservando todos os registros — **NAs onde as fontes têm coberturas diferentes** (IDHM censitário, IDEB/SAEB bienal, CNES/ANS em 4 anos, docentes até 2020). Variáveis incorporadas por bloco:

Bloco	Variáveis trazidas ao painel
Demográfico	cagr_pop_2010_2025, cagr_pop_2010_2022, sh_pop_branca/preta/parda/indigena
Assistência IDHM/ desigualdade	perc_pop_bf, perc_pop_bpc, transf_pc_real idhm, classifica_idhm, gini, taxa_pobreza_pct, taxa_ext_pobreza_pct
Educação qualidade	ideb_iniciais, ideb_finais, taxa_aprovacao_iniciais, taxa_aprovacao_finais
Educação infraestrutura	n_escolas_total, perc_internet, perc_docentes_superior, tdi_ef_anos_iniciais, taxa_abandono_ef_anos_iniciais
Saúde mortalidade	tmi, tmi_suavizado, perc_cesareas, perc_prenatal_adequado
Saúde infraestrutura	n_estabelecimentos, n_hospitais, n_ubs, leitos_totais, leitos_sus_total, leitos_sus_per_1000, estab_per_10k, beneficiarios_ans, perc_cobertura_ans

FIX 15/05/2026: a saúde-infraestrutura entra no painel com as variáveis **absolutas** (contagens e estoques) além das relativas, para permitir análises detalhadas no painel. **Trava de unicidade** (stopifnot) impede gravar com chave (id_municipio, ano) duplicada. Antes de cruzar com outras dimensões, **filtrar pelos anos disponíveis** de cada indicador.

Correções e decisões aplicadas (linha do tempo)

Data	Decisão / Correção	Onde
04/11/2025	Recorte PN-13 fixado como definição institucional do convênio (TdR assinado)	Cabeçalho
15/05/2026	id_municipio do CNES já no padrão IBGE 7 dígitos (pós-patch C2); padronização de grupo/subgrupo com o D1; filtro ANS por exclusão de odontológico; saúde-infra absoluta no painel	Seções [7], [8]

Data	Decisão / Correção	Onde
21/05/2026	Redefinição PN-15 → PN-13; grupo com 3 valores (pantanal_norte / polo_metropolitano / resto_mt)	Helpers classifica_grupo/classifica_subgrupo
11/06/2026 (D-3)	BF/BPC tratados como bases mensais → média mensal de identificadores distintos; janela 2013-2024	Seção [2]
11/06/2026 (D-4)	TMI suprimida se NV < 30; tmi_suavizado = taxa agregada de janela 3 anos	Seção [6]
11/06/2026 (M-2)	perc_cobertura_ans com teto de 100%	Seção [7]
11/06/2026	Dedups defensivos C15 e C34 + travas stopifnot de unicidade da chave	Seções [3], [8]
14/06/2026	perc_docentes_superior — limiar condicional ao ano (escala muda em 2015)	Seção [5]
14/06/2026	Urbanização C13b integrada ao d3_demografico (Censo 2022)	Seção [1]

Limitações Gerais da Dimensão 3

Limitação	Impacto	Recomendação
IDHM/Gini/pobreza censitários	Último ano = 2010 (defasagem de 15 anos)	Rotular “Censo 2010”; usar como cortes, não como série anual
Subíndices IDHM (E/L/R) ausentes na versão congelada (Fase I)	d3_idhm.csv traz só idhm sintético	Recoletar C15 com os subíndices mapeados; script já preparado (any_of)
perc_pop_bf / perc_pop_bpc = benefícios/famílias, não pessoas	Valores podem superar 100% e não representam % de indivíduos	Rotular “famílias/benefícios por 100 hab”; não somar a outras taxas populacionais
BF 2012 truncado, 2025 parcial; BPC só 2019+ na fonte	Totais irreais nas pontas; BPC série curta	Restringir a 2013-2024; tratar BPC pré-2019 como ausente
perc_docentes_superior — fonte C18 docentes só até 2020	NA em 2021-2024 (não é bug; é ausência da fonte)	Usar 2009-2020; aguardar nova coleta do Censo Escolar docentes
perc_docentes_especial com NA em 2011-2014 (especializacao)	Pode instabilizar esses 4 anos	Tratar 2011-2014 com cautela; revisar à parte
TMI bruta instável em municípios pequenos	tmi = NA quando NV < 30	Esperado; usar tmi_suavizado para tendência

Limitação	Impacto	Recomendação
perc_cobertura_ans com teto de 100%	Perde magnitude em polos (até 166,9% real)	Usar beneficiarios_ans absoluto para polos
CNES/ANS em 4 snapshots; IDEB/SAEB bienal (sem 2025)	NAs amplos no painel anual	Filtrar pelos anos disponíveis antes de cruzar
SAEB (C20) preenchido só em 2011–2021 — o rótulo de rede de 2023 não casa com o filtro total/total	media_*/perc_nivel_adequado_* vazios em 2005–2009 e 2023	Usar o IDEB para a série completa 2005–2023; SAEB começa efetivamente em 2011
Colunas residuais de pivot (*_todos_1_4_, _4ano, _14ano)	Quase ou inteiramente vazias (61–100% NA); não são etapas de análise	Ignorar; usar _iniciais/_finais (IDEB) e _5ano/_9ano/_12ano (SAEB)
Pré-natal adequado = só categoria 7+ consultas (critério MS estrito)	“Déficit” parece maior que em definições frouxas	Reportar o critério ao lado do número
Composição racial e urbanização = Censo 2022 replicado	Não é série temporal; retrato de 2022	Rotular “Censo 2022”; não interpretar como evolução
Peso de Rondonópolis (≈53% da população do PN-13)	Agregados ponderados ≈ Rondonópolis + Cáceres (71,6%)	Reportar média simples E ponderada e os extremos; quando relevante, com/sem Rondonópolis
Chave SIM/SINASC = município de residência	Difere de estatísticas por local de ocorrência (hospitais em polos)	Documentar; coerente com indicadores populacionais

Notas geradas em 14/06/2026 — DSIP-MT. Base validada para o Relatório D3/PSDM Parcial I. Atualizado em 09/07/2026 — reconciliação da documentação com as bases congeladas da Fase I (contagens, períodos e variáveis conferidos contra os CSVs entregues). Script: 02_Analise/Scripts/D3_PSDM.R Deflator (assistência social): C35_deflator_pib.csv (INPC base 2010 = 100 → R\$ de 2024) Referência geográfica: Dados/painel_mestre/municipios_ref.csv (141 MT; 13 PN; mapa cod6→cod7)